

문제 정의

사용자는 아직도 많은 기능을
제대로 사용하지 못하고 있습니다.

복잡한 가진 기능과 분산된 제어 방식 때문에,
사용자는 상황에 맞는 기능을 찾기 못하고 놓치고 있습니다.
결국, 제품이 제공하는 가치를 온전히 경험하지 못합니다.

이 기능은
어디에 있지?



AI 비서가 상황을 이해하고,
최적의 기능을 자동으로 추천·실행!

상황에 맞는
기능을 준비했어요!



상황 인식
시간·날씨·사용 패턴을 이해



맞춤 추천
지금 필요한 기능을 선택



자동 실행
선택 없이 바로 실행



홈 상태 제어
실물 가전(LED 등)까지 제어

왜 문제가 되나요? (Why Now)

1. 너무 많은 기능, 너무 복잡한 사용법

평균 가전 1대당 20~50개 이상 기능 탑재
하지만 사용자는 극히 일부만 사용

쓰고 있는 기능
20%



2. 기능을 찾기 어려운 구조와 분산된 제어

각 제품/앱마다 다른 UI, 용어, 제어 방식
같은 기능도 어디에 있는지 모름



3. 상황에 맞는 기능을 놓치고 있음

시간, 날씨, 사용자 상태에 따라
유용한 기능이 있지만 자동 추천/제안 부족



데이터로 보는 현실

가전 기능 사용률 20%

사용자는 전체 기능의
약 20%만 사용
(출처: LG 내부 사용자 조사)

가전 기능 인지율 ≤40%

절반 이상의 사용자가
기능 존재 자체를 인지하지 못함
(출처: LG 내부 사용자 조사)

앱 전환/탐색 시간 2~3분


원하는 기능을 찾기까지
평균 2~3분 소요
(출처: LG 내부 사용자 태스트)

사용자에게 돌아오는 결과

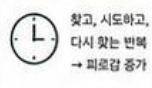
제품의 가치를 100% 경험하지 못함



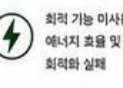
사용자 만족도 & 재구매 의도 하락



불필요한 시간·노력 소모



에너지 & 비용 낭비



우리가 해결하고자 하는 것

상황을 이해하는 AI 비서가
최적의 기능을 추천하고 실행하여,
당신의 집이 더 똑똑하고, 편리하고, 효율적으로!

데모 서비스 구성과 사용자 경험

대화형 인터페이스와 홈 상태 실물 시뮬레이션, 가전제품 실물 제어를 결합해 추천부터 실행 결과까지 보여줍니다

AI가 집을 이해하고,
필요한 기능을 알아서 연결합니다.

1. AI 비서



2. 홈 상태 실물 시뮬레이션 + 가전제품 실물 제어



데모 흐름 (사용자 여정)

1. 대화 시작
사용자가 음성 또는 텍스트로 요청
2. 상황 해석
발화 내용 + 시나리오 상태를 함께 해석
3. 기능 추천
적절한 자동화/기능을 역선 제안
4. 실행/반영
추천 기능을 실행하고, 실물 시뮬레이션 + 가전제품 제어로 결과 반영
5. 응답 피드백
실행 결과와 상태를 음성/텍스트로 안내

현재 데모에서 보여주는 것



대표 시나리오

일상 대화

자연스러운 대화를 통해 필요한 기능을 발견
(예: 하루 요약, 날씨, 일정, 기기 상태 확인)
→ 관련 가전/시뮬레이션 실행 및 LED 반영



회의 후 귀가

늦은 귀가 상황에 맞춘
조명·공조·가전 자동화 및 실물 제어
(예: 조명/온도 조절, 공기청정기 실행, 스타일러 코스 시작)
→ 시뮬레이션 + 가전 실행 결과 확인




운동 후 귀가

운동 후 회복과 휴식을 위한
기능을 알아서 준비하고 실물 제어/LED 반영
(예: 공기 청정, TV 켜기, 조명 전환, 로봇청소기 대기)
→ 시뮬레이션 + 가전 실행 결과 확인

홈루션 AI 비서 E2E Architecture

시스템 전체 아키텍처



기술 차별화 포인트



3D Avatar 생성

Avatar

Image-to-3D Model, 얼굴 3D 오브젝트 생성 → Blender 정리 → 얼굴 파츠 생성 → VRM/UI 반영



Voice 서빙 효율화

Voice

미리 로드/워밍업을 통해 초기 지연 최소화 및 자주 발생하는 응답 캐시



Qwen3 30B 모델 서빙

Brain

Tensor Parallelism으로 30B급 LLM을 여러 노드에 분산하여 구동



분산 LLM 성능 포인트

속도

1Gbps 유선 스위치 허브 기반으로
노드 간 통신 병목을 최소화하고
10~12 TPS 속도 달성

응답 지연을 줄이는 실행 흐름

답변이 다 끝나길 기다리지 않고, 생성되는 문장부터 바로 말하게 만드는 구조입니다.



홈루션 AI 구성




분산 처리로 더 큰 모델을 더 빠르게: Tensor Parallelism

모델을 여러 장치에 나눠 담고, 같은 레이어를 동시에 계산해 대형 모델 서빙과 10~12 TPS 속도를 구현



현재 대용 기준

대형 모델 분산 서빙 + 10~12 TPS



왜 강점인가



더 큰 모델 생방

한 장치 메모리 한계를 넘어
더 큰 모델 구동



동시 계산

여러 장치가 같은 시점에
연산을 지연 감소



처리 속도 향상

실시간 응답에 가까운
10~12 TPS 달성



확장 가능한 구조

장치 수를 늘려 더 큰 모델·
더 높은 성능으로 확장 가능



한 줄 이해

Tensor Parallelism은 하나의 큰 모델을 여러 장치에 나눠 담고,
같은 레이어 계산을 동시에 수행하는 **분산 추론 방식**입니다.



핵심 기술

Tensor Parallelism



효과 1

대형 모델 서빙 가능



효과 2

10~12 TPS